Hệ thống tự động tạo package từ dữ liệu dạng bảng cho hệ thống LLM

Bùi Xuân Hoan
FPT University
Ho Chi Minh City, Vietnam
bhoan2006@gmail.com

Phạm Lê Minh
FPT University
Ho Chi Minh City, Vietnam
minhlek332@gmail.com

Phan Văn Tú
FPT University
Ho Chi Minh City, Vietnam
vantu12772@gmail.com

***Tóm tắt*—Bài báo trình bày một hệ thống tự động chuyển dữ liệu dạng bảng thành gói tri thức (knowledge package) phục vụ tái sử dụng bộ máy hỏi đáp trên nhiều lĩnh vực. Hệ thống tiếp nhận CSV/Excel, khảo sát toàn bảng, sử dụng mô hình ngôn ngữ để đề xuất và rà metadata, sau đó tạo profile, mapping, định danh bản ghi và bằng chứng theo từng ô. Giá trị nguồn được giữ nguyên; loader đọc lại file nguồn để kiểm tra package trước khi sử dụng. Thực nghiệm trên 11 bảng thuộc nhiều lĩnh vực, với tổng cộng 3.381 dòng, ghi nhận 11/11 bảng hoàn tất tạo và nạp package, với thời gian trung bình 16,00 giây mỗi bảng. Kiểm thử hỏi đáp bổ trợ trên 500 câu cơ bản đạt 84,60% khi yêu cầu đồng thời đúng kết quả và bằng chứng nguồn. Kết quả cho thấy khả năng tự động hóa việc chuẩn bị dữ liệu, nhưng thành công đóng gói không đồng nghĩa metadata được xác nhận đúng về ngữ nghĩa hoặc mọi câu hỏi đều được trả lời chính xác.**

***Từ khóa*—dữ liệu dạng bảng, knowledge package, tự động hóa, metadata, bằng chứng nguồn, hỏi đáp đa lĩnh vực.**

I. Giới thiệu

Khi chuyển một hệ thống hỏi đáp sang dataset mới, dữ liệu thường cần được chuyển đổi thành các bản ghi, trường thông tin, định danh và nguồn đối chiếu mà bộ máy xử lý có thể sử dụng. Nếu thực hiện thủ công, mỗi bảng lại cần một lượt cấu hình riêng, dù cấu trúc đầu vào vẫn là các dòng và cột quen thuộc. Bài toán của nghiên cứu này là tự động hóa khâu chuẩn bị đó cho CSV/Excel, thay vì xây dựng thêm một hệ thống hỏi đáp chuyên biệt cho từng lĩnh vực.

Giải pháp sử dụng knowledge package như một hợp đồng giữa dữ liệu nguồn và bộ máy hỏi đáp. Package chứa file nguồn, profile, mapping và bằng chứng có định danh; runtime sử dụng cùng cơ chế nạp cho các bảng khác nhau. Mô hình ngôn ngữ hỗ trợ diễn giải cấu trúc, trong khi code chịu trách nhiệm bảo toàn giá trị và kiểm tra tính nhất quán. Việc này không huấn luyện lại model hay tự sinh các quy tắc nghiệp vụ của lĩnh vực mới.

Trọng tâm bài báo gồm quy trình phân tích và tạo package tự động, cơ chế kiểm chứng với nguồn, và thực nghiệm chuyển đổi trên nhiều dataset. Khả năng hỏi đáp được sử dụng như một phép kiểm thử sau chuyển đổi, không phải nội dung kiến trúc chính của báo cáo.

II. Hệ thống tự động tạo gói tri thức

Fig. 1 trình bày luồng chuẩn bị dữ liệu và điểm kết nối với bộ máy hỏi đáp. Phần tạo và kiểm chứng package được thực hiện khi nhận dataset; phần hỏi đáp sử dụng lại package đã tạo.

A. Tiếp nhận và khảo sát dữ liệu

Hệ thống nhận CSV UTF-8 hoặc Excel định dạng XLSX. Với workbook nhiều sheet, người dùng chọn một sheet; các ký hiệu ô thiếu có thể được chỉ định theo nguồn. Bộ đọc kiểm tra header, độ dài dòng và giới hạn kích thước, đồng thời giữ bản sao file gốc để đối chiếu. Phạm vi hiện tại là một bảng mỗi package, tối đa 20 MiB, 32 cột và 100.000 ô; ô công thức Excel cần được chuyển thành giá trị trước khi tải lên.

Code khảo sát toàn bảng để suy kiểu, đếm ô thiếu, thống kê giá trị phân biệt và xác định độ duy nhất. Chuỗi định danh có số 0 đầu được giữ là chuỗi; số 0 không bị xem là ô thiếu. Giá trị có kiểu phục vụ phép tính, còn biểu diễn ô nguồn được giữ cho bằng chứng. Những dòng có tên giống nhau không tự bị gộp.

B. Đề xuất metadata và tạo mapping

Mô hình Qwen3-8B Q4_K_M nhận tên cột, thống kê và ví dụ giá trị để đề xuất metadata, gồm vai trò cột, mô tả và các điểm mơ hồ. Một lượt gọi tiếp theo rà mô tả và chọn tối đa hai cột tên. Cả hai lượt đều yêu cầu đầu ra JSON theo schema; không giao cho model sinh code chuyển đổi hoặc thay đổi giá trị ô.

Code kiểm tra đề xuất có bao phủ đúng các cột nguồn. Cột không duy nhất không được giữ vai trò định danh duy nhất. Mô tả không được chấp nhận hoặc bị đánh dấu mơ hồ sẽ trở về header nguồn. Sau đó, hệ thống tạo profile với tập thuộc tính riêng của bảng và mapping từ cột sang ID trường như `c001`, `c002`. Profile mô tả giao diện dữ liệu cho runtime, không phải một bộ chính sách nghiệp vụ được tự động xác nhận.

C. Sinh định danh, bằng chứng và package

Mỗi dòng có ID ổn định theo thứ tự bản ghi, độc lập với tên hiển thị. Với ô có dữ liệu, hệ thống tạo một đoạn bằng chứng chứa giá trị nguồn, ID dòng, ID trường, vị trí nguồn (locator) và hash nội dung. Locator ghi dòng/cột CSV hoặc sheet/dòng/cột Excel, cho phép truy ngược kết quả về đúng ô.

Tập thuộc tính được ghi vào `profile.json`; cấu trúc và mapping được ghi vào `table.json`. Các file JSONL lưu

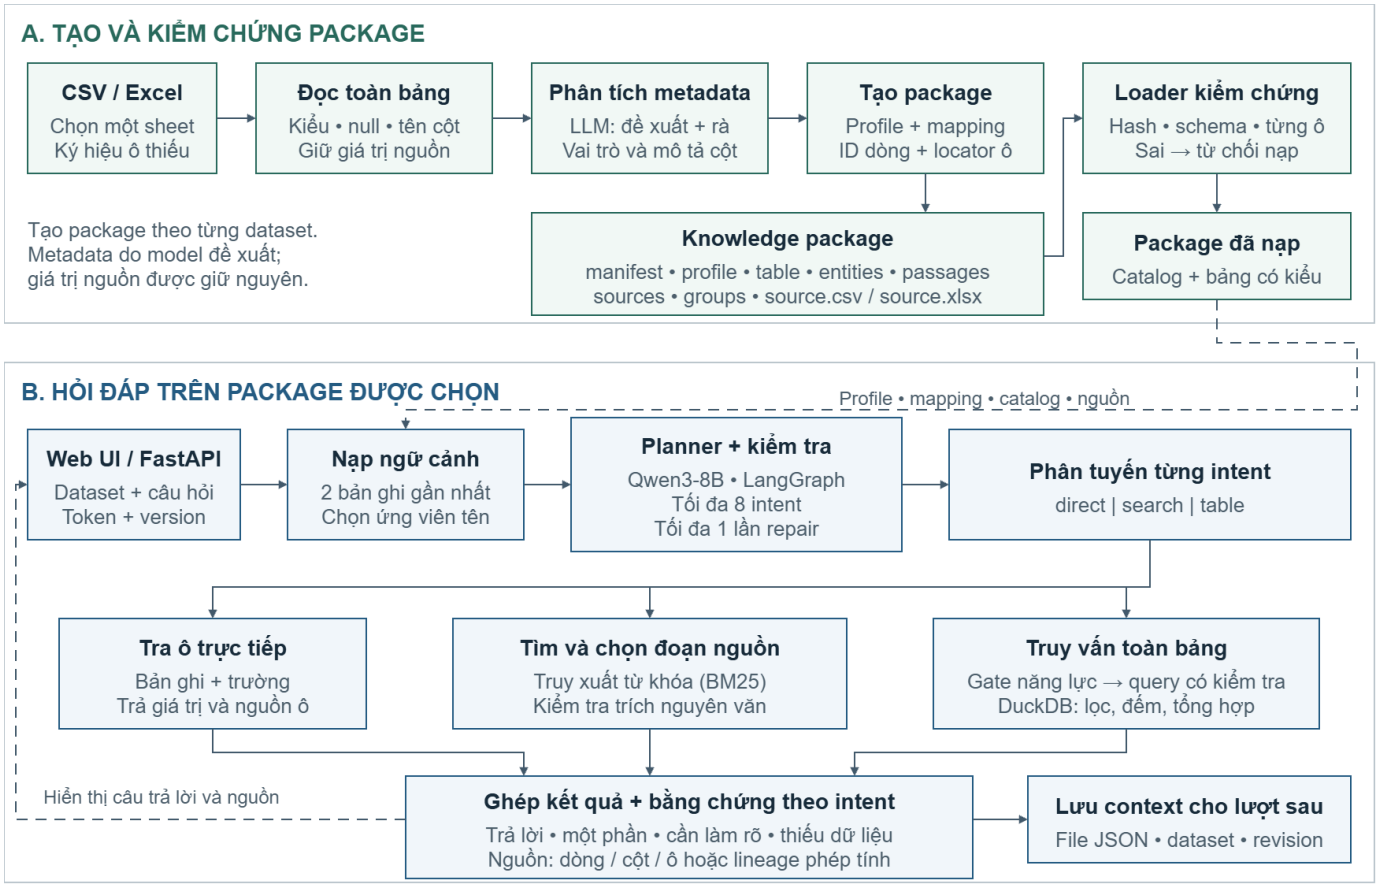


Fig. 1. Pipeline tạo và kiểm chứng knowledge package cùng bước bàn giao cho bộ máy hỏi đáp. Trọng tâm nghiên cứu là khối A; khối B minh họa việc sử dụng package sau chuyển đổi.

danh mục bản ghi, nguồn và bằng chứng; nhóm bản ghi được lưu riêng dưới dạng JSON. File CSV/XLSX gốc được lưu kèm. Manifest ghi phiên bản, hash, kích thước các file và số bản ghi/bằng chứng, đồng thời được ghi cuối như dấu mốc hoàn tất package.

D. Kiểm chứng và bàn giao

Loader kiểm tra các file bắt buộc, schema và SHA-256, sau đó đọc lại file nguồn để dựng lại mapping, bản ghi và bằng chứng từng ô. Nếu có sai khác, package bị từ chối nạp. Đây là kiểm chứng tính toàn vẹn và liên kết với nguồn, không phải chứng nhận mô tả metadata đúng về ngữ nghĩa.

Package hợp lệ có thể được tải xuống dạng ZIP hoặc nạp qua adapter bảng. Trong phép thử sử dụng, bộ máy hỏi đáp tra ô, tìm đoạn nguồn hoặc thực hiện lọc/tổng hợp trên bảng có kiểu. Mỗi request chọn một package; hệ thống hỗ trợ tối đa tám intent và giữ hai bản ghi gần nhất trong context, nhưng chưa kết hợp nhiều package trong cùng một câu hỏi.

III. Thực nghiệm và kết quả

A. Thiết lập đánh giá

Thực nghiệm sử dụng Qwen3-8B Q4_K_M qua llama.cpp trên GPU NVIDIA GeForce RTX 5060 Ti 16 GB, máy có khoảng 32 GiB RAM. Model dùng temperature 0, seed 42 và context 12.288 token. Yêu cầu được gửi qua API nội bộ trong môi trường máy phát triển đã giảm tải, không phải môi trường cô lập hoàn toàn.

Table I liệt kê 11 bảng dùng kiểm thử. Bảng hành chính là Excel gốc có 42 dòng; ReciFineGold pilot được chuyển từ JSONL sang CSV trước thực nghiệm. Các bảng còn lại là CSV. Mỗi bảng được đưa qua cùng API tạo package, không gán mapping thủ công; chỉ truyền sheet/ký hiệu ô thiếu khi cần.

Mỗi dataset có một lượt tạo gói. Thời gian được đo từ lúc gửi file đến khi API trả trạng thái sẵn sàng, bao gồm đọc bảng, phân tích metadata, ghi package và kiểm chứng; đây không phải thời gian chạy riêng của model.

B. Khả năng tự động chuyển đổi

Cả 11/11 bảng, tổng 3.381 dòng, hoàn tất tạo và nạp package. Thời gian trung bình giữa các bảng là 16,00 giây, nhỏ nhất 4,42 giây và lớn nhất 45,24 giây. Các package đã tạo chứa ánh xạ cho toàn bộ 89 cột nguồn. Hệ thống không cần thay code theo từng bảng trong lượt thử này. Trong lượt đo bổ sung, tốc độ sinh metadata để tạo package trung bình đạt 63,26 token/giây.

Kết quả xác nhận khả năng tự động hoàn tất quy trình trên những đầu vào đã chọn, không phải tỷ lệ hiểu đúng metadata.

TABLE I
TẠO PACKAGE TỰ ĐỘNG VÀ PHÂN BỐ CÂU HỎI CƠ BẢN

Dataset	Dòng	Cột	Câu	Thời gian (s)
Thủ tục hành chính	42	12	80	17,47
Auto MPG	398	9	60	17,36
Penguins	344	8	50	15,19
Bike Daily	731	16	45	35,26
Wine Red	1599	12	45	45,24
Vật tư văn phòng	137	7	45	10,86
Transfer Assets	41	7	40	8,76
Transfer Courses	28	6	40	8,32
Du lịch	5	3	35	4,42
Mượn thiết bị	6	6	35	8,54
ReciFineGold pilot	50	3	25	4,64

Mỗi bảng một lượt tạo gói; thời gian E2E qua API nội bộ. Cả 11 bảng hoàn tất tạo và nạp package.

TABLE II
KIỂM THỬ HỎI ĐÁP BỔ TRỢ TRÊN PACKAGE TỰ TẠO

Bộ kiểm thử	Đạt đầy đủ	Chỉ nội dung
500 câu cơ bản	423/500	437/500
	84,60%	87,40%
176 lượt DEV	130/176	140/176
	73,86%	79,55%

Đạt đầy đủ: đúng kết quả/trạng thái và bằng chứng nguồn. Chỉ nội dung: chưa yêu cầu bằng chứng. Lỗi được giữ trong mẫu số.

Loader kiểm tra cấu trúc và giá trị theo nguồn, trong khi ý nghĩa mô tả do model đề xuất chưa có bộ nhãn độc lập để chấm. Vì vậy, package hợp lệ vẫn có thể chứa diễn giải chưa phù hợp hoặc không đủ để giải quyết một yêu cầu nghiệp vụ.

C. Kiểm thử hỏi đáp sau chuyển đổi

Để kiểm tra package có thể được sử dụng, bộ thử bổ trợ gồm 500 câu cơ bản và 176 lượt DEV được tạo từ các bảng nguồn rồi đóng băng trước inference. Bộ cơ bản gồm 400 câu một intent, 76 câu hai intent và 24 câu ba intent. DEV có 16 lượt mỗi dataset, gồm multi-intent đến tám intent, lọc/tổng hợp, thiếu dữ liệu, mơ hồ và hội thoại nhiều lượt. Đây là các bộ phát triển theo template và dữ liệu nguồn, không phải tập kiểm thử độc lập được giữ kín.

Theo Table II, tiêu chí đạt đầy đủ yêu cầu đúng số task, trạng thái, dữ liệu và bằng chứng nguồn cho từng intent có đáp án. Chỉ số chỉ nội dung bỏ yêu cầu về bằng chứng nhưng giữ kiểm tra kết quả. Bộ cơ bản đạt 423/500 câu đầy đủ; DEV đạt 130/176, trong đó một lượt lỗi HTTP được giữ trong mẫu số. Không thay câu sai sau khi đo.

Bảy dataset đạt toàn bộ câu cơ bản, nhưng Penguins chỉ đạt 9/50 và Bike Daily đạt 24/45. Kết quả cho thấy cùng một cơ chế đóng gói không bảo đảm chất lượng hỏi đáp đồng đều. Độ trễ toàn yêu cầu ở bộ cơ bản trung bình 9,02 giây, P95 22,43 giây. DEV còn có ca kéo dài đến 324,64 giây. Các thời gian này tách biệt với tạo package; tỷ lệ repair chưa được báo cáo trong đợt đo chính.

D. Rà soát hallucination theo dữ liệu nguồn

Đánh giá bổ sung bằng AI rà 163 đầu ra API trên 13 bảng, gồm 11 dataset đã thử và hai bảng giả lập kiểm tra an toàn. Chưa ghi nhận hallucination trong phần đã chốt nhãn, gồm 122 đầu ra có phát biểu thực tế được đối chiếu với dữ liệu nguồn; 39 đầu ra chỉ hỏi lại/từ chối được đếm riêng. Hai đầu ra còn lại chưa chốt nhãn vì chỉ trả giá trị 0 khi câu hỏi yêu cầu diễn giải điều kiện miễn cọc hoặc phí tài liệu, chưa làm rõ ngoại lệ trong nguồn. Vì vậy, chưa công bố tỷ lệ hallucination cho toàn bộ bộ kiểm tra. Đây là lần rà bằng chính trợ lý AI đã tham gia phát triển hệ thống trên bộ phát triển, chưa có xác nhận độc lập của con người. Phép rà chỉ xét nội dung trả lời theo bảng nguồn, không xác nhận ngữ nghĩa của metadata tự sinh hoặc tính đúng của mọi lựa chọn bản ghi và trường thông tin.

IV. GIỚI HẠN VÀ KẾT LUẬN

Phạm vi hiện tại là một bảng có header rõ ràng, không phải workbook bố cục tự do hay liên kết nhiều bảng. Người dùng vẫn cần chọn sheet, khai báo ký hiệu ô thiếu và xử lý công thức khi nguồn yêu cầu. Hệ thống chưa tự tạo chính sách nghiệp vụ hoặc giải mã mã số khi không có bảng mã.

Hai lượt đề xuất/rà metadata không thay thế đánh giá của người có hiểu biết về dữ liệu. Mô tả vẫn có thể thêm nghĩa hoặc đơn vị thiếu căn cứ, dù package vượt qua kiểm tra hash và từng ô. Thực nghiệm tạo gói mới có một lượt mỗi bảng, chủ yếu trên bảng nhỏ và vừa; bộ hỏi đáp là tập phát triển và chưa có đối chứng loại bỏ bước rà metadata. Do đó chưa thể kết luận tính tổng quát trên mọi dataset hay mức cải thiện do riêng bước rà soát mang lại.

Bài báo trình bày quy trình tự động chuyển CSV/Excel thành knowledge package có profile, mapping, định danh và bằng chứng gắn với nguồn. Kết quả trên 11 dataset cho thấy có thể chuẩn hóa khâu chuẩn bị dữ liệu và bàn giao cho cùng bộ máy hỏi đáp mà không viết mapping riêng cho từng bảng. Hướng tiếp theo là bổ sung đánh giá ngữ nghĩa của metadata, cơ chế người dùng xác nhận/chỉnh mapping và đo lặp lại việc tạo gói trên các bảng đa dạng hơn.